VIETNAM NATIONAL UNIVERSITY HO CHI MINH CITY
HO CHI MINH CITY UNIVERSITY OF TECHNOLOGY
FACULTY OF COMPUTER SCIENCE AND ENGINEERING



Học sâu và Ứng dụng trong Thị giác Máy tính - CO5085

Assignment Report

CNN vs Transformer trên tập ảnh lớn

Advisor(s): Le Thanh Sach
Nguyen Quoc Minh
Student(s): Nguyen Tran Phuoc 2470576

HO CHI MINH CITY, OCTOBER 2026

Contents

1 Giới thiệu tập dữ liệu và Lý do lựa chọn **4**
1.1 Tập dữ liệu GTSRB 4
1.2 Lý do chọn tập dữ liệu 4

2 Mô tả tập dữ liệu, Split và Augmentation **4**
2.1 Phân chia tập dữ liệu 4
2.2 Tiền xử lý và Augmentation 5

3 Giao thức Thí nghiệm **6**
3.1 Các kiến trúc mô hình 6
3.2 Kế hoạch Huấn luyện và Đóng băng (Training & Freezing Modes) 7
3.3 Chỉ số đánh giá 7

List of Figures

2.1 Biểu đồ phân bố số lượng ảnh (Histogram) của 43 lớp trong tập huấn luyện 5
2.2 Một số ảnh mẫu 6

List of Tables

Listings

1 Giới thiệu tập dữ liệu và Lý do lựa chọn

1.1 Tập dữ liệu GTSRB

Trong bài tập lớn A1, nhóm quyết định lựa chọn tập dữ liệu GTSRB (German Traffic Sign Recognition Benchmark). Đây là tập dữ liệu ảnh màu đa lớp phổ biến dùng trong bài toán nhận dạng biển báo giao thông.

Số lượng lớp gồm 43 lớp (bao gồm giới hạn tốc độ, cấm vượt, biển báo nguy hiểm, đường ưu tiên, v.v.).

1.2 Lý do chọn tập dữ liệu

Theo yêu cầu của đề bài, tập dữ liệu cần có kích thước đủ lớn và độ khó cao hơn E1. GTSRB thỏa mãn các tiêu chí sau:

- **Kích thước tập ảnh lớn:** Tổng số ảnh huấn luyện lên tới hơn 39,000 ảnh, đủ lớn để thấy rõ sự khác biệt về hiệu năng giữa CNN và Vision Transformer (ViT).
- **Tính đa dạng và thử thách:** Các bức ảnh trong GTSRB có kích thước và điều kiện ánh sáng, góc chụp rất đa dạng (từ 15×15 pixel đến 250×250 pixel). Một số ảnh bị mờ, lóa sáng hoặc bị che khuất một phần.
- **Ứng dụng thực tế cao:** Nhận diện biển báo là một thành phần quan trọng trong các hệ thống xe tự lái thực tế.

2 Mô tả tập dữ liệu, Split và Augmentation

2.1 Phân chia tập dữ liệu

Tập dữ liệu gốc đã được chia sẵn thành hai phần chính:

- **Tập Huấn luyện:** 39,209 ảnh. Nhóm sẽ trích xuất 20% từ tập này để làm tập Validation (xác thực) phục vụ cho việc theo dõi quá trình hội tụ và tuning siêu tham số.
- **Tập Kiểm tra:** 12,630 ảnh, dùng để đánh giá mô hình cuối cùng (tính toán Accuracy và vẽ Confusion Matrix ở mốc A1.2).

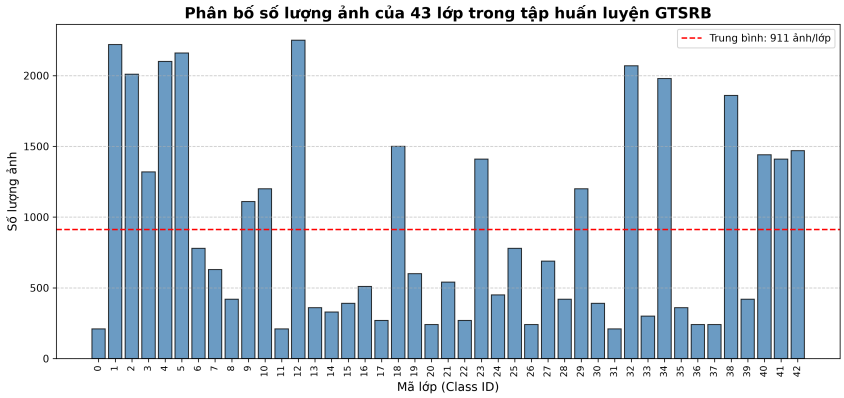


Figure 2.1: Biểu đồ phân bố số lượng ảnh (Histogram) của 43 lớp trong tập huấn luyện

2.2 Tiền xử lý và Augmentation

Do GTSRB có các ảnh mang kích thước khác nhau và đôi khi bị mất cân bằng số lượng mẫu giữa các lớp, nhóm đề xuất quy trình DataLoader và Augmentation như sau:

- **Tiền xử lý cơ bản:**
  - **Resize:** Thay đổi kích thước toàn bộ ảnh về 224×224 để phù hợp với kích thước đầu vào tiêu chuẩn của các mô hình Pretrained họ CNN và Transformer (đặc biệt là ViT).
  - **Normalize:** Chuẩn hóa giá trị pixel bằng Mean và Standard Deviation của ImageNet hoặc của chính tập GTSRB.
- **Train Augmentation:** Để chống overfitting, nhóm sử dụng:
  - Random Rotation (xoay góc ngẫu nhiên $\pm 15°$).
  - Color Jitter (chỉnh sáng tối, độ tương phản nhẹ). Không dùng Random Horizontal Flip do biển báo giao thông (ví dụ: rẽ trái, rẽ phải) có tính hướng, việc lật ngang sẽ làm sai nhãn.

Một số mẫu ảnh từ tập dữ liệu GTSRB



Figure 2.2: Một số ảnh mẫu

3 Giao thức Thí nghiệm

Để so sánh hiệu quả giữa CNN và Transformer theo đúng yêu cầu Mục 4 của đề bài, nhóm sẽ thực hiện các cấu hình kiến trúc và chiến lược huấn luyện sau:

3.1 Các kiến trúc mô hình

1. **Họ kiến trúc CNN:** ResNet-50 (hoặc ConvNeXt-Tiny). Đại diện cho mạng tích chập sâu truyền thống, có Inductive Bias tốt với dữ liệu ảnh.

2. **Họ kiến trúc Transformer:** ViT-Base/16 (Vision Transformer) hoặc Swin-T. Đại diện cho kiến trúc dựa trên Self-Attention.

3.2 Kế hoạch Huấn luyện và Đóng băng (Training & Freezing Modes)

Nhóm sẽ sử dụng thư viện `torchvision` và `timm` / `Hugging Face` để tải các mô hình. Các chế độ huấn luyện sẽ được áp dụng cho cả hai họ mô hình trên:

- **Chế độ 1 - Train From-Scratch:** Khởi tạo trọng số ngẫu nhiên hoàn toàn. Giúp đánh giá xem mô hình (đặc biệt là ViT) có thể học tốt trên tập dữ liệu ∼39k ảnh mà không cần tri thức từ ImageNet hay không.
- **Chế độ 2 - Pretrained + Freeze Backbone:** Sử dụng trọng số ImageNet-1k. Đóng băng toàn bộ các layer trích xuất đặc trưng (Backbone). Chỉ thay thế và huấn luyện lớp Classification Head cuối cùng (43 output neurons).
- **Chế độ 3 - Pretrained + Partial Freeze:**
  - *Với ResNet-50:* Đóng băng các block đầu (ví dụ conv1, layer1, layer2), chỉ cho phép cập nhật gradient ở layer3 và layer4.
  - *Với ViT:* Đóng băng 6-8 blocks Transformer Encoder đầu tiên, fine-tune các blocks cuối để mô hình thích ứng với đặc thù cục bộ của biển báo.
- **Chế độ 4 - Pretrained + Full Finetune (Cập nhật toàn bộ):** Khởi tạo từ trọng số ImageNet nhưng mở khóa toàn bộ các tham số của mạng, kết hợp với Learning Rate nhỏ để cập nhật tri thức tối đa cho tập GTSRB.

3.3 Chỉ số đánh giá

- **Chỉ số đo lường hiệu năng:** Accuracy (%) trên tập Validation và tập Test. Báo cáo thêm F1-Score do tập GTSRB có hiện tượng mất cân bằng lớp.
- **Phân tích tài nguyên:** Ghi nhận và so sánh Số lượng tham số (Trainable Parameters), Thời gian chạy 1 epoch, và dung lượng bộ nhớ VRAM sử dụng.

References