ĐẠI HỌC BÁCH KHOA

Khoa Khoa học và Kỹ thuật Máy tính

Báo cáo Bài tập lớn A2 (Mốc A2.1)

Phân đoạn Ngữ nghĩa Cảnh đường Giao thông Đô thị

Môn học: Học sâu và Ứng dụng trong Thị giác Máy tính (CO5085)

Năm học & Học kỳ:	Học kỳ 261 (2026–2027)
Giảng viên hướng dẫn:	Thầy Lê Thành Sách, Thầy Nguyễn Quốc Minh
Tên nhóm:	**AutoVision**
Sinh viên thực hiện:	Nguyễn Trần Phước (MSSV: **2470576**)
Email:	ntphuoc.sdh242@hcmut.edu.vn
Chủ đề đã chọn (A2.1):	Chủ đề 1 — Phân đoạn ảnh ngữ nghĩa
Link GitHub Repo:	https://github.com/NguyenTranPhuoc/CO5085_Assignment
Link GitHub Pages:	https://nguyentranphuoc.github.io/CO5085_Assignment/

Thành phố Hồ Chí Minh, Năm 2026

Mục lục

Tổng quan Đề tài **2**

1 Bài toán và Tập dữ liệu (EDA) **2**
1.1 Mô tả Tập dữ liệu Cityscapes 2
1.2 Nhận xét EDA (Số liệu thực đo trên tập Train) 4

2 Dataset, DataLoader, Augmentation & Metrics **4**
2.1 Ánh xạ Nhãn và Chiến lược Augmentation Đồng bộ 4
2.2 Thước đo Đánh giá (Evaluation Metrics) 5

3 Bài báo Khoa học Phân tích (Selected Paper) **6**

4 Kế hoạch Pipeline, Huấn luyện & So sánh Phương pháp (≥ 2 biến thể) **6**

Tổng quan Đề tài

Trong hệ thống hỗ trợ lái xe tiên tiến (*Advanced Driver-Assistance Systems – ADAS*) và xe tự hành (*Autonomous Driving*), việc hiểu cảnh đường giao thông tới mức độ từng điểm ảnh (*pixel-level semantic segmentation*) đóng vai trò cốt lõi để xác định vùng mặt đường có thể di chuyển, vỉa hè, phương tiện, người đi bộ và hệ thống biển báo/đèn tín hiệu. Đề tài này xây dựng pipeline phân đoạn ngữ nghĩa trên tập dữ liệu chuẩn công nghiệp **Cityscapes** và phân tích chuyên sâu kiến trúc **SegFormer (NeurIPS 2021)** đối sánh với nhánh mạng tích chập **DeepLabV3+ / U-Net**.

Bảng 1 tóm tắt thông tin khóa đề tài ở mốc A2.1 (trích xuất từ `a2_1_summary.json` và trang `a2.html`):

Bảng 1: Tổng hợp thông tin khóa đề tài ở Mốc A2.1.

Hạng mục Mốc A2.1	**Nội dung đăng ký**
Chủ đề (Topic)	Chủ đề 1 — Phân đoạn ảnh ngữ nghĩa: Semantic Segmentation of Urban Scenes (Cityscapes)
Tập dữ liệu (Dataset)	**Cityscapes Dataset** (`gtFine`: 19 lớp `trainId` chuẩn + `ignore_index = 255`)
Phân chia chuẩn (Splits)	Train: 2,975 ảnh | Val: 500 ảnh | Test: 1,525 ảnh (Tổng: 5,000 ảnh thực tế)
Bài báo tham chiếu (Paper)	*SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers*
Tác giả & Hội nghị	Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M. Alvarez, Ping Luo (**NeurIPS 2021**)
Thước đo đánh giá (Metrics)	**mIoU**, **mDice (Dice Score / F1)**, **Pixel Accuracy (PA)**, **Per-class IoU**, **FPS**
Các biến thể so sánh	**Model 1:** DeepLabV3+ / U-Net (`ResNet-50 / ResNet-34`, CE + Dice Loss) **Model 2:** SegFormer-B0 (`MiT-B0`, CE + Dice Loss) **Model 2a (Ablation):** SegFormer-B0 (`MiT-B0`, Cross-Entropy thuần)

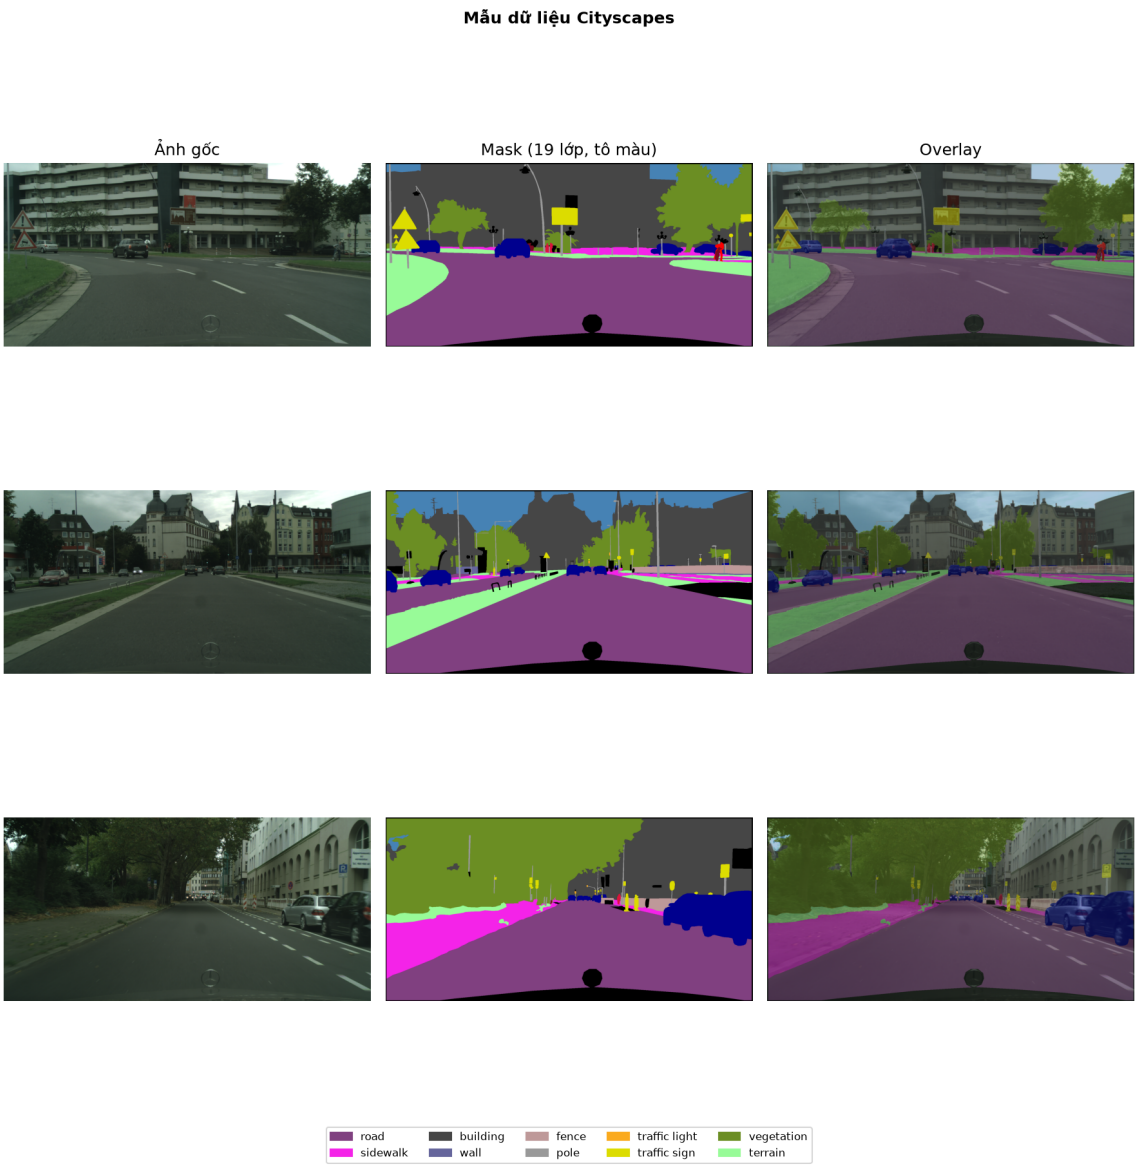
1 Bài toán và Tập dữ liệu (EDA)

1.1 Mô tả Tập dữ liệu Cityscapes

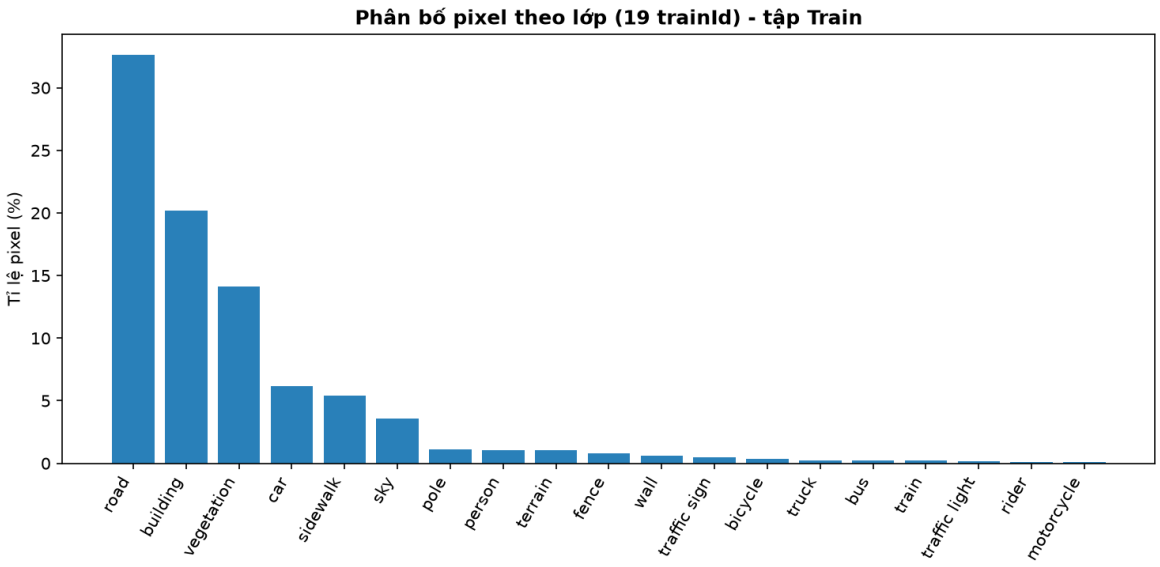
- **Nguồn dữ liệu:** Cityscapes Dataset (Fine Annotations) — thu thập từ camera hành trình gắn trên ô tô tại 50 thành phố châu Âu (`using_synthetic_placeholder = false`).
- **Quy mô & Phân chia chuẩn:** Tổng cộng **5,000** ảnh độ phân giải gốc 1024×2048 được gán nhãn pixel chi tiết:
  - **Train set:** 2,975 ảnh (18 thành phố).
  - **Validation set:** 500 ảnh (3 thành phố độc lập: Frankfurt, Lindau, Münster).
  - **Test set:** 1,525 ảnh (6 thành phố).
- **Số lớp đánh giá: 19 lớp ngữ nghĩa chuẩn** (`trainId` từ 0 đến 18) chia thành 7 nhóm:
  - *Flat:* `road`, `sidewalk`.
  - *Construction:* `building`, `wall`, `fence`.
  - *Object:* `pole`, `traffic light`, `traffic sign`.
  - *Nature:* `vegetation`, `terrain`.
  - *Sky:* `sky`.
  - *Human:* `person`, `rider`.

– *Vehicle:* `car`, `truck`, `bus`, `train`, `motorcycle`, `bicycle`.

Các vùng nền phụ hoặc vùng biên không xác định được gán về nhãn `ignore_index = 255`.



Hình 1: Mẫu ảnh gốc, mask phân đoạn (19 lớp, tô màu chuẩn Cityscapes) và overlay trên tập Train (trích từ notebook A2.1).



Hình 2: Phân bố tỷ lệ diện tích Pixel của 19 lớp ngữ nghĩa (`trainId`) trên tập Train, tính trên toàn bộ 2,975 ảnh.

1.2 Nhận xét EDA (Số liệu thực đo trên tập Train)

Từ kết quả thống kê trên toàn bộ 2,975 ảnh huấn luyện (Hình 2), tập dữ liệu Cityscapes thể hiện hiện tượng **mất cân bằng lớp cực kỳ lớn (Extreme Class Imbalance)**:

- Ba lớp nền (`road` **32.64**%, `building` **20.21**%, `vegetation` **14.10**%) chiếm tới hơn **66**% tổng số pixel hợp lệ.
- Ngược lại, các lớp quan trọng bậc nhất về an toàn giao thông như `traffic sign` (**0.49**%), `traffic light` (**0.18**%), `rider` (**0.12**%), `motorcycle` (**0.09**%) chỉ chiếm dưới **0.5**% diện tích ảnh.
- **Ý nghĩa đối với thiết kế mô hình:** Sự mất cân bằng này ảnh hưởng trực tiếp tới lựa chọn hàm mất mát ở Mục 4 — cần kết hợp **Cross-Entropy Loss** với **Dice Loss** để tránh việc mô hình chỉ học tốt các lớp nền phổ biến mà bỏ sót các đối tượng giao thông kích thước nhỏ.

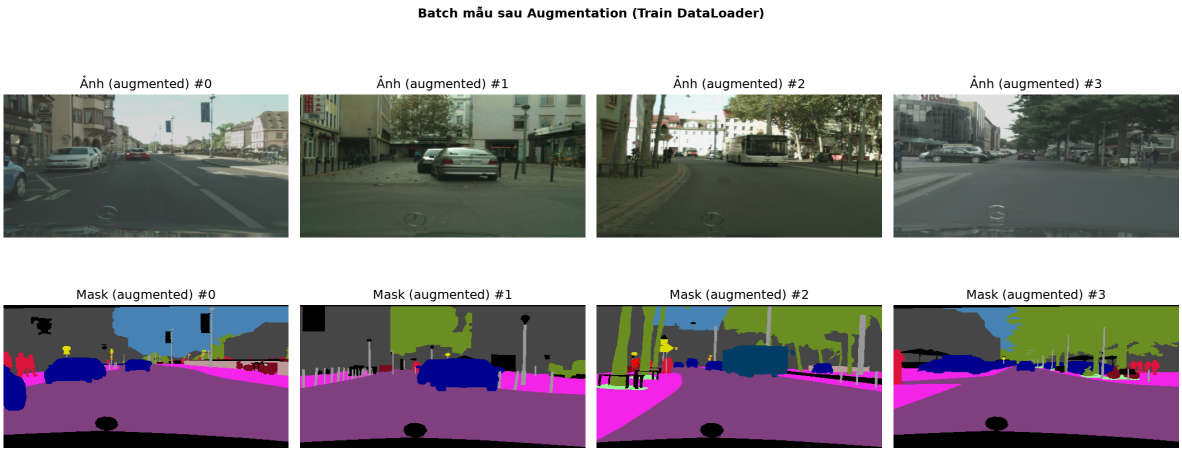
2 Dataset, DataLoader, Augmentation & Metrics

2.1 Ánh xạ Nhãn và Chiến lược Augmentation Đồng bộ

- **Ánh xạ nhãn (Label Mapping):** Chuyển đổi 34 mã nhãn gốc (`labelId`) của Cityscapes về **19 `trainId` chuẩn** (từ 0 đến 18), các lớp nền phụ/vùng biên gán về `ignore_index = 255`.
- **Chiến lược Augmentation (Đồng bộ trên cả Image và Mask, `seed = 42`):**
  - `RandomResizedCrop` / Resize về kích thước huấn luyện `crop_size = [256, 512]` (hoặc 512×1024, giữ nguyên tỷ lệ khung hình $1:2$ của camera ô tô).

Ảnh RGB được nội suy bằng `Bilinear`, trong khi mặt nạ phân đoạn dùng nội suy `Nearest-Neighbor` để bảo toàn nhãn nguyên.

- `RandomHorizontalFlip(p=0.5)` và `ColorJitter` (thay đổi độ sáng, tương phản để mô phỏng biến thiên ánh sáng ngoài trời).
- Chuẩn hóa (`Normalize`) theo thống kê chuẩn ImageNet: mean $= [0.485, 0.456, 0.406]$, std $= [0.229, 0.224, 0.225]$.



Hình 3: Một batch ảnh/mask thực tế sau augmentation (`RandomResizedCrop`, `Flip`, `ColorJitter`) lấy trực tiếp từ `Train DataLoader`.

2.2 Thước đo Đánh giá (Evaluation Metrics)

Trên tập Validation/Test, các pixel có nhãn target $= 255$ được loại trừ trước khi tính toán các thước đo chuẩn trên $C = 19$ lớp:

1. **mIoU (Mean Intersection over Union):** Thước đo chính trung bình trên 19 lớp giao thông:

$$\text{mIoU} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{\text{TP}_c}{\text{TP}_c + \text{FP}_c + \text{FN}_c} \tag{1}$$

2. **mDice (Mean Dice Score / F1):** Đánh giá độ nhạy phân đoạn, đặc biệt với các vật thể nhỏ (biển báo, đèn giao thông, người đi bộ):

$$\text{mDice} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{2\,\text{TP}_c}{2\,\text{TP}_c + \text{FP}_c + \text{FN}_c} \tag{2}$$

3. **Pixel Accuracy (PA)**, **Per-class IoU** và tốc độ suy luận thời gian thực **FPS (Frames Per Second)**.

3 Bài báo Khoa học Phân tích (Selected Paper)

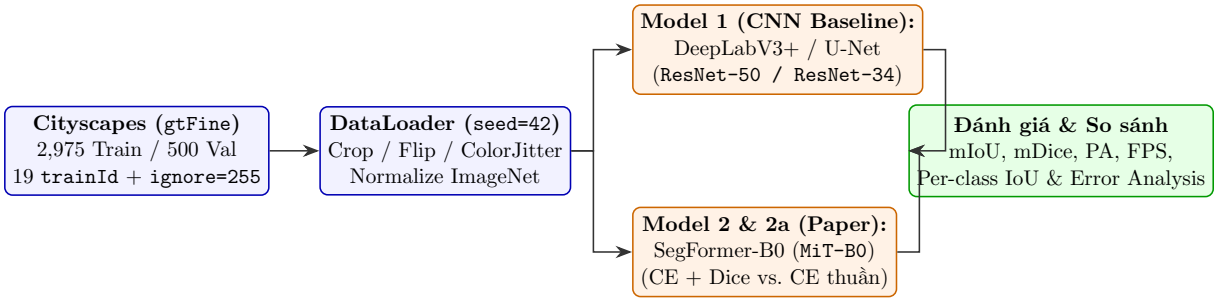
- **Trích dẫn (Citation):** Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M. Alvarez, and Ping Luo, *"SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers"*, in **Advances in Neural Information Processing Systems (NeurIPS)**, vol. 34, pp. 12077–12090, 2021.
- **Liên kết:** arXiv:2105.15203 | Official GitHub (NVlabs/SegFormer).

Phân tích kiến trúc cốt lõi của SegFormer:

1. **Ý tưởng cốt lõi (Hierarchical Mix Transformer – MiT):** Thiết kế bộ mã hóa phân cấp trích xuất đặc trưng đa tỷ lệ ($\frac{1}{4}, \frac{1}{8}, \frac{1}{16}, \frac{1}{32}$) thông qua *Overlapping Patch Merging*, kết hợp cơ chế *Efficient Self-Attention* (giảm chiều chuỗi với tỷ lệ R để giảm chi phí bậc hai $\mathcal{O}(N^2)$ xuống $\mathcal{O}(N^2/R)$) và khối *Mix-FFN* dùng 3×3 `Depthwise Conv` để loại bỏ hoàn toàn Positional Encoding cố định.
2. **Bộ giải mã nhẹ (All-MLP Decoder):** Hợp nhất đặc trưng đa tầng chỉ bằng các phép chiếu tuyến tính (`MLP`), giúp biến thể **SegFormer-B0** chỉ nặng **3.7**M tham số nhưng đạt độ chính xác vượt trội và tốc độ suy luận cao trên cảnh đường Cityscapes.

4 Kế hoạch Pipeline, Huấn luyện & So sánh Phương pháp (≥ 2 biến thể)

Nhóm thiết kế pipeline đối sánh trực tiếp giữa hai họ kiến trúc **CNN** và **Hierarchical Vision Transformer** cùng khảo sát hàm mất mát (*Loss Ablation*), như minh họa trong Hình 4 và Bảng 2.



Hình 4: Sơ đồ kiến trúc Pipeline huấn luyện và đối sánh thực nghiệm trên tập dữ liệu Cityscapes.

Bảng 2: Bảng kế hoạch các cấu hình mô hình và biến thể đối sánh trong Bài tập lớn A2.

Cấu hình	Kiến trúc Mô hình	Backbone	Hàm mất mát (Loss)	Mục tiêu đối sánh
Model 1 (Baseline)	DeepLabV3+ / U-Net	ResNet-50 / ResNet-34 (CNN)	Cross-Entropy + Dice	Đại diện nhánh CNN tích chập đa tỷ lệ (ASPP)
Model 2 (Paper)	SegFormer-B0	MiT-B0 (Hierarchical ViT)	Cross-Entropy + Dice	Đánh giá hiệu năng & tốc độ của Transformer
Model 2a (Ablation)	SegFormer-B0	MiT-B0 (Hierarchical ViT)	Cross-Entropy thuần	Đánh giá tác động của Dice Loss lên các lớp nhỏ